

项目名称：基于对抗样本的大语言模型安全性评估与对齐

📌 项目背景

- ✅ **贴近前沿**：安全对齐是当前大语言模型（LLMs）应用中的关键问题，对抗样本作为评估和提升鲁棒性的重要方式，已成为诸多顶会（如 ICLR、NeurIPS、ACL）关注重点。
- ✅ **工具丰富**：已有开源工具链可直接使用，如：
 - [TextAttack](#)：对抗样本生成与训练框架；
 - [OpenPrompt](#)：用于 prompt 工程的统一接口；
 - [lm-evaluation-harness](#)：语言模型评估工具框架。
- ✅ **能做出结果**：可量化比较对抗攻击前后模型准确率变化，并尝试对抗训练提升鲁棒性，具有良好的展示性与可视化。
- ✅ **任务可控，门槛较低**：任务围绕“攻击—评估—防御—验证”闭环展开，对初学者友好，阶段成果清晰。

🚀 项目关键词

对抗攻击、ChatGPT、鲁棒性、安全性、自然语言处理、微调

🔥 项目路径建议（适合大创团队：3-5人，周期约3-4个月）

第一阶段（2-3周）：基础学习与工具搭建

- 学习自然语言处理基础与预训练模型框架：
 - HuggingFace Transformers（模型加载与微调）
 - HuggingFace Datasets（数据集管理）
- 学习对抗攻击基础：
 - 阅读中文博客、综述性论文
 - 熟悉 TextAttack 文档与API
- 实操任务：
 - 在 Google Colab 安装并运行 TextAttack
 - 用 TextAttack 攻击一个基础分类模型（如 BERT on SST-2）

第二阶段（3-5周）：鲁棒性评估实验

- 选择评估模型：
 - 英文模型：BERT、RoBERTa
 - 中文模型：ChatGLM、BELLE、LLaMA-2
- 选择攻击方法：

- TextFooler、BAE、DeepWordBug 等
 - 实验内容：
 - 对每个模型运行不同攻击方法
 - 比较攻击前后性能指标变化：
 - 准确率 (Accuracy)
 - 攻击成功率 (Attack Success Rate)
 - 扰动率 (Perturbation Rate)
 - 输出结果表格、可视化图表
-

第三阶段 (3-4周)：对齐机制与防御方法探索

- 对抗训练 (Adversarial Training)：
 - 使用 TextAttack 自带 adversarial training pipeline
 - Prompt-based 防御策略：
 - 为提示添加安全导向语句 (如“请避免生成不当内容”)
 - 引入 reward 模型：
 - 使用开源 toxicity 检测模型打分
 - 尝试结合 basic reward shaping 实验
-

第四阶段 (2-3周)：总结与撰写

- 撰写项目总结报告 (可参考论文格式)
 - 编写技术文档与实验复现说明
 - 准备最终答辩材料 (PPT、演示视频)
 - 整理可运行 notebook 与项目 GitHub 仓库, 便于展示与后续拓展
-

可用资源

- HuggingFace Hub 上的开源模型与数据集
 - Google Colab (免费GPU环境)
 - TextAttack、OpenPrompt、lm-evaluation-harness 工具库
 - 相关论文与中文综述资料
-

项目预期成果

- 1-2 个完整实验报告 + GitHub 项目文档
- 可视化对抗攻击实验结果
- 改进前后鲁棒性提升数据

✳️ 研究方法、研究方案及可行性

本项目围绕当前大语言模型在对抗性输入条件下鲁棒性不足的问题，开展基于对抗样本的模型脆弱性评估与对齐机制研究。研究方案采用“评估—改进—验证”的技术路径，具体分为以下三个阶段：

📌 阶段一：模型与攻击框架构建

- 选取具有代表性的预训练语言模型（如 BERT、RoBERTa、ChatGLM、LLaMA）。
- 使用 TextAttack、OpenAttack 等开源框架搭建对抗攻击实验平台。
- 选定标准任务数据集（如 SST-2、AG News、TNEWS）用于分类与对抗攻击实验。
- 引入典型文本攻击方法（TextFooler、BAE、PWWS 等）实现多样性对抗扰动。

📌 阶段二：鲁棒性评估与量化分析

- 对模型在原始与对抗样本上的性能进行系统评估。
- 核心评估指标包括准确率变化、攻击成功率（ASR）、扰动率（perturbation rate）、预测一致性等。
- 对比分析不同模型在不同攻击方式下的鲁棒性差异，揭示模型脆弱区域。

📌 阶段三：对抗训练与安全对齐机制构建

- 尝试标准对抗训练（Standard Adversarial Training）与混合数据训练（Hybrid Fine-tuning）等策略。
- 探索防御性提示语（prompt shielding）、reward-based scoring 等轻量对齐机制。
- 验证改进后的模型在安全性、鲁棒性与任务准确性方面的综合表现。

✅ 可行性分析

- 所用模型、数据集与工具链均为开源资源，环境部署简单，适合大创周期。
- 项目团队成员将分工明确，配合教师指导开展阶段性任务，项目具有较强的可执行性与落地性。

✳️ 项目的特色与创新点

本项目面向当前自然语言处理系统部署中的“安全性与对齐”问题，具有明确研究指向与工程价值。其特色与创新体现在以下几个方面：

🎯 1. 问题导向突出，贴近真实应用需求

聚焦大语言模型在面对恶意输入时的脆弱性问题，结合实际安全攻击场景，具有很强的现实针对性。

2. 攻防一体化设计，实验路径完整

构建从“攻击—评估—防御—验证”全链条闭环，避免仅停留在算法或模型层面，实现方法链条式思维训练。

3. 面向中文模型，兼顾本土适配性

项目不仅涵盖英文评估，还将应用于中文预训练模型（如 ChatGLM、BELLE），探索本土语言场景下的安全对齐机制，体现语言多样性与工程拓展性。

4. 工具链成熟、可复制性强

依托成熟开源框架与标准评估流程，项目具备良好的复现性与可推广价值，适合进一步扩展为教学案例或科研立项雏形。

5. 成果形式多样，展示效果突出

可形成实验数据报告、可视化图表、可运行 notebook、演示视频等形式，便于项目答辩、竞赛展示或教学使用。